

مستندات برنامه RETRO Demo

عنوان پروژه

شبیهسازی مفهومی مقاله "Improving Language Models by Retrieving from Trillions of Tokens"

هدف برنامه

این برنامه یک شبیهسازی آموزشی از مقاله معروف DeepMind درباره مدل RETRO است. هدف اصلی، نمایش مفاهیم کلیدی مقاله به صورت عملی و قابل درک است، بدون نیاز به سختافزار پیشرفته یا دیتابیسهای عظیم.

اهداف اصلی برنامه:

1. نمایش مفهوم بازیابی اطلاعات از یک دیتابیس بزرگ
2. شبیهسازی مکانیزم Chunked Cross-Attention (توجه تکه‌تکه شده)
3. مقایسه عملکرد مدل با و بدون بازیابی
4. تحلیل نشت داده (Data Leakage) و تأثیر آن بر عملکرد
5. ارائه خروجیهای گرافیکی برای درک بهتر مفاهیم

ساختر برنامه

برنامه از ۵ کلاس اصلی تشکیل شده است که هر کدام بخشی از مقاله را پیاده‌سازی میکنند:

۱. کلاس `RetroDatabase` (دیتابیس بازیابی)

توضیح: این کلاس وظیفه شبیه‌سازی دیتابیس عظیم ۲ تریلیون توکنی مقاله را دارد.

نحوه کار:

۱. دیتابیس با اسناد تصادفی پر میشود
۲. برای هر سند، یک Embedding شبیه‌سازی شده ساخته میشود
۳. هنگام جستجو، شباهت بین تکه ورودی و همه اسناد محاسبه میشود
۴. k تکه با بیشترین شباهت به عنوان همسایه انتخاب میشوند

۲. کلاس `SimpleLanguageModel` (مدل زبان پایه)

توضیح: یک مدل زبان ساده که جایگزین Transformer پیچیده مقاله میشود.

۳. کلاس `RetroModel` (مدل اصلی RETRO)

توضیح: این کلاس، ترکیب دیتابیس و مدل زبان را مدیریت میکند.

۴. کلاس `ChunkedCrossAttentionDemo` (مکانیزم توجه تکه‌تکه شده)

توضیح: شبیهسازی مهمترین بخش مقاله - مکانیزم CCA.

مراحل اجرا:

1. دریافت حالات پنهان و همسایهها
2. تقسیم حالات پنهان به تکهها
3. برای هر تکه، Cross-Attention با همسایههایش انجام میشود
4. خروجیها ترکیب شده و به لایه بعدی میروند
5. توابع نمایش (Visualization Functions)

برنامه شامل ۴ تابع برای نمایش گرافیکی است:

تابع	خروجی	کاربرد
`demo\_retrieval\_benefits`()	متن در کنسول	نمایش مزایای بازیابی
`visualize\_neighbor\_retrieval`()	نمودار میلهای	نمایش توزیع شباهت همسایهها
`analyze\_leakage`()	نمودار خطی	تحلیل نشت داده
`compare\_models`()	دو نمودار جعبهای	مقایسه عملکرد با/بدون بازیابی

🔍 تطابق با مقاله اصلی

جدول مقایسه مفاهیم

مفهوم در مقاله پیاده‌سازی در برنامه توضیح
MassiveText (دیتابیس) `RetroDatabase` شبیه‌سازی با داده‌های تصادفی
Embedding BERT Embeddings تصادفی شبیه‌سازی بردارهای BERT
Chunking (تقسیم به تکه) پارامتر `chunk_size=64` دقیقاً مطابق مقاله
k-NN Retrieval تابع `retrieve_neighbors`() جستجوی k همسایه نزدیک
Chunked Cross-Attention کلاس `ChunkedCrossAttentionDemo` پیاده‌سازی رابطه (۴) مقاله
RETRO ON/OFF پارامتر `use_retrieval` مقایسه با/بدون بازیابی
Data Leakage Analysis تابع `analyze_leakage`() تحلیل بخش ۴.۴ مقاله

📈 نتایج و تحلیل

مشاهده ۱: بازیابی عملکرد را بهبود میبخشد

مشاهده ۲: نشت داده تأثیر دارد

مشاهده ۳: مکانیزم CCA مؤثر است